

Interpretación de resultados

Distribución de longitud de documentos

El análisis de longitud mostró:

Media: 23.62 tokens

Mediana: 23 tokens

Percentil 95: 33 tokens

Máximo: 73 tokens

Esto lo interpretamos de la siguiente manera:

- La longitud de los documentos es relativamente homogénea.
- La media y la mediana son muy similares, indicando una distribución equilibrada.
- El 95% de los documentos contiene 33 tokens o menos después del preprocesamiento.
- Sólo una pequeña proporción presenta textos considerablemente más largos.

Conclusión

El valor obtenido para el percentil 95 $\text{max_len} = 33$ constituye una referencia adecuada para futuros modelos Transformer, ya que permitiría representar la mayoría de los documentos minimizando padding innecesario y reduciendo el costo computacional.

Top Bigramas

Los bigramas más frecuentes fueron:

new york

oil price

united states

prime minister

president bush

wall street

Esto lo interpretamos de la siguiente manera:

Estos resultados reflejan correctamente la naturaleza periodística del corpus:

- **new york, wall street, united states** indican fuerte presencia de noticias económicas y políticas.

- **prime minister** y **president bush** reflejan contenido geopolítico e internacional.
- **oil price** evidencia cobertura de mercados energéticos y financieros.

También aparecen algunos términos repetitivos:

ap ap , afp afp, reuters Reuters que provienen de agencias de noticias utilizadas como fuente del corpus.

Top Trigramas

Los trigramas más frecuentes incluyen:

new york reuters, boston red sox, prime minister ariel, president george bush, president vladimir putin.

Esto lo interpretamos de la siguiente manera:

Los trigramas permiten observar mayor contexto semántico:

- **new york reuters** identifica la procedencia periodística.
- **boston red sox** corresponde al dominio deportivo.
- **president george bush** y **president vladimir putin** aparecen en noticias políticas internacionales.
- **prime minister ariel sharon** muestra eventos geopolíticos característicos del período cubierto por AG News.

Esto confirma que el pipeline preservó correctamente información relevante de las entidades mencionadas.

Distribución de clases

Esto lo interpretamos de la siguiente manera:

AG News es un dataset balanceado, por lo que:

- No se anticipan problemas importantes de desbalance de clases.
- Accuracy y F1-Score deberían comportarse de forma consistente.
- Los modelos posteriores podrán entrenarse sin aplicar técnicas específicas de balanceo.

Conclusión final

El pipeline de preprocesamiento permitió transformar el corpus AG News en una representación textual más limpia y adecuada para tareas de clasificación supervisada. Se aplicaron procesos de normalización, eliminación de ruido mediante expresiones regulares, remoción de stopwords y lematización utilizando SpaCy, reduciendo la variabilidad léxica del corpus sin perder información semántica relevante.

El análisis exploratorio mostró que los documentos presentan una longitud moderada, con una media de 23,6 tokens y un percentil 95 de 33 tokens. Este resultado será utilizado como referencia para la configuración de la longitud máxima de secuencia en modelos Transformer posteriores.

Los bigramas y trigramas más frecuentes reflejan adecuadamente la temática periodística del dataset, destacándose entidades geográficas, figuras políticas y términos característicos de noticias internacionales, deportivas y financieras. La ausencia de ruido significativo en los N-gramas evidencia que el proceso de limpieza fue efectivo.

Finalmente, la distribución de clases se presenta equilibrada, lo que reduce el riesgo de sesgo durante el entrenamiento de modelos de clasificación y permite utilizar métricas como Precision, Recall y F1-Score de manera confiable. En conjunto, los resultados obtenidos indican que el corpus se encuentra correctamente preparado para las etapas posteriores de modelado mediante TF-IDF y arquitecturas basadas en Transformers.